背景

1. 由于开源项目依赖的更新，漏洞的修补，某些依赖服务的版本已经不被允许使用，因此重新构建了一版API镜像，并且将API镜像与模型镜像上传到了公开的注册中心，后续服务可直接按文档启动服务，无需重新构建镜像。
2. 此处，构建镜像的Dockerfile 提供给到大家，可以参考使用。
3. 若是，直接使用镜像也无法启动服务，有可能是CUDA版本不支持的缘故，本镜像支持12.4版本的CUDA驱动
4. 如果，是CUDA不支持导致的，可以使用Windows整合包

文档

1. 源码版本：https://github.com/RVC-Boss/GPT-SoVITS/tree/20250606v2pro
2. docker构建资源：https://pan.baidu.com/s/1lBduIZNNX3Qdl5uYC6CnBA?pwd=sq3u
3. window整合版（win>=10）：https://pan.baidu.com/s/1Z4-WMpRTfPaArsA6FSIkmw?pwd=wizg

window整合包

课程使用版本

GPT-SoVITS-v2pro-20250604

下载整合包资源（2选1）

1. 零声百度云盘下载：https://pan.baidu.com/s/1Z4-WMpRTfPaArsA6FSIkmw?pwd=wizg
2. 开源项目官方下载：https://www.yuque.com/baicaigongchang1145haoyuangong/ib3g1e/dkxgpiy9zb96hob4#KTvnO

启动服务

1. 解压整合包
2. 根目录下添加go-api.bat批处理文件

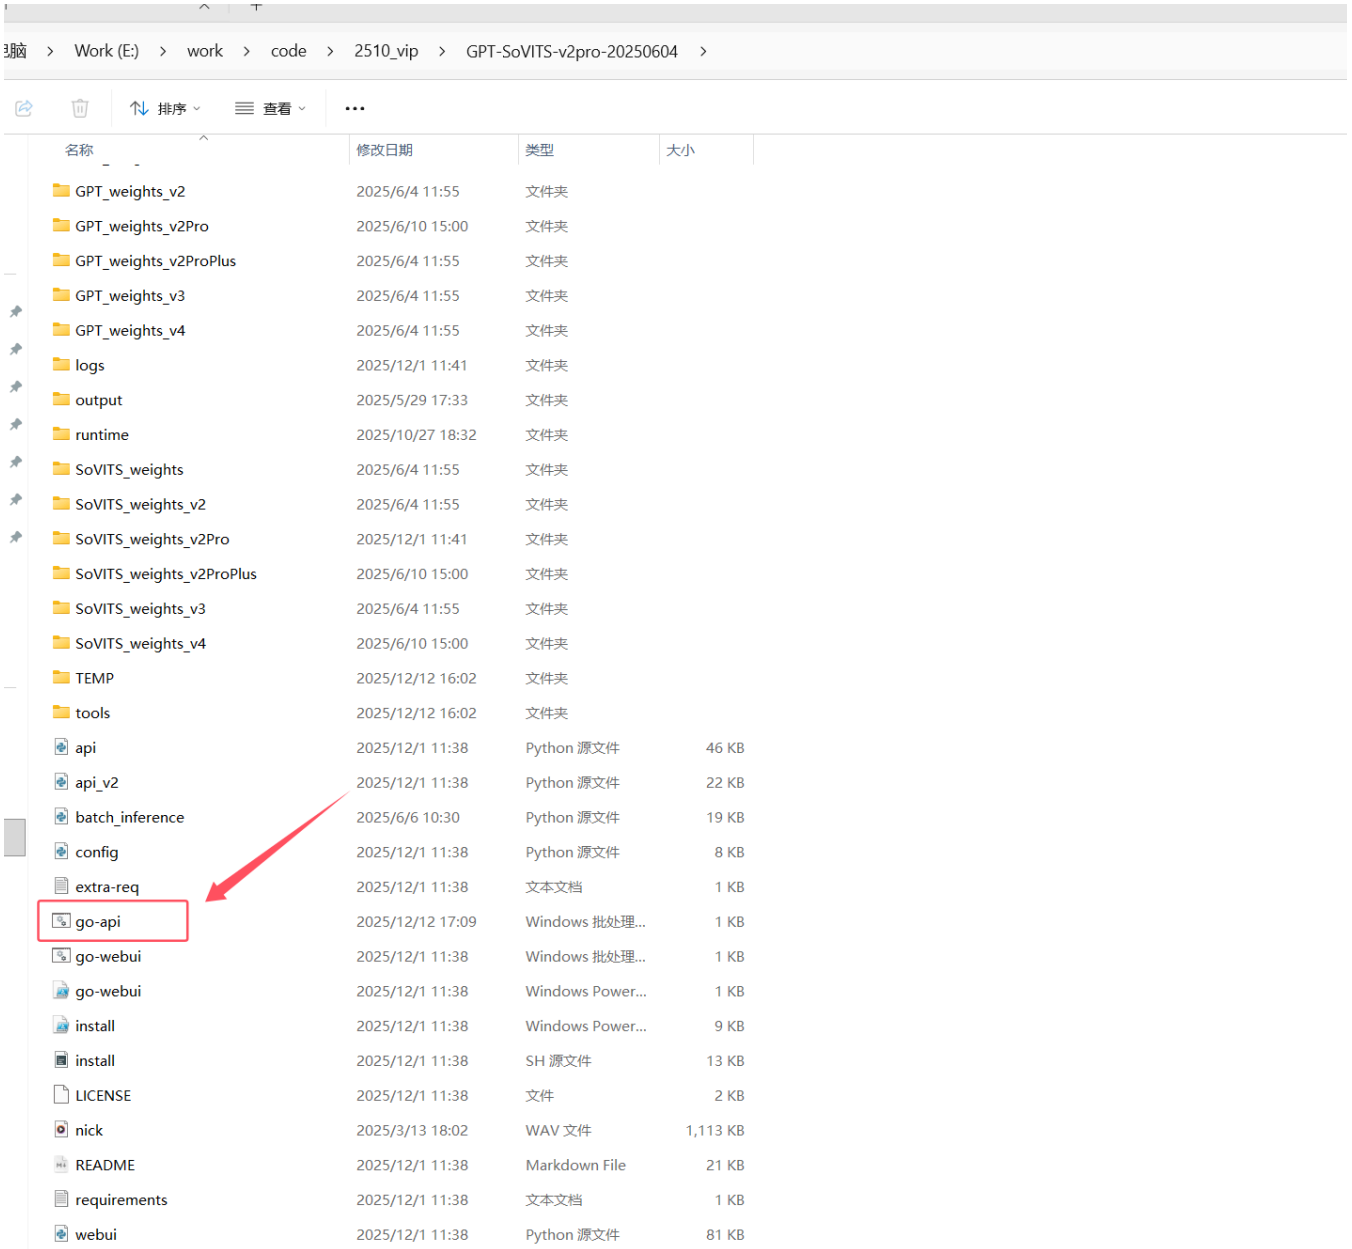

3. 批处理文件内容如下

```
runtime\python.exe api.py -dl zh -p 9880
pause
```

4. 双击批处理文件启动程序

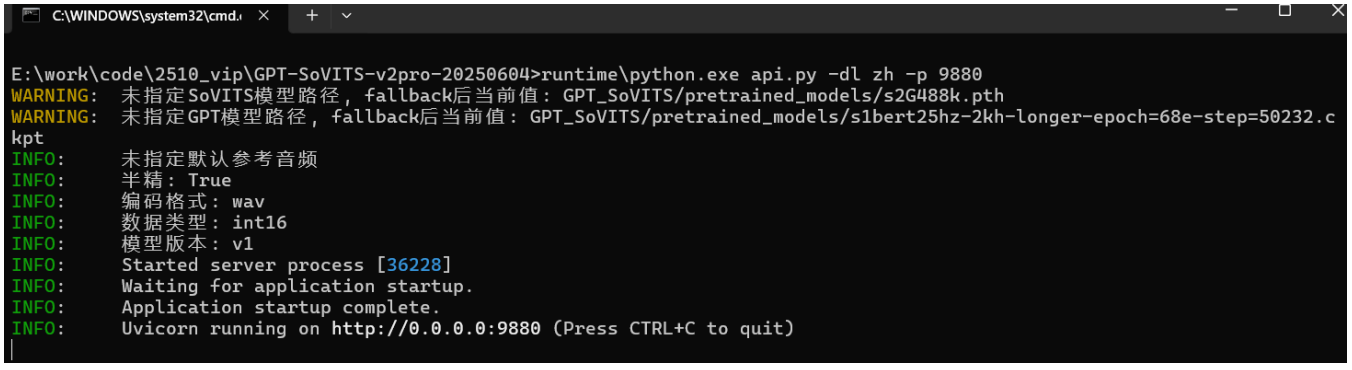

CPU推理

1. 若机器不知此cuda则修改批处理文件，采用CPU推理

```
runtime\python.exe api.py -dl zh -d "cpu" -fp -p 9880
pause
```

2. 双击批处理文件启动程序

准备参考音频和参考文本

1. 准备参考文本

```
云原生是一种软件开发和交付的方法论，旨在实现高度扩展、弹性和可靠的应用程序
```

2. 根据参考文本，录制一个5~10s的音频，作为参考音频
3. 将参考音频复制整合包的根目录（即批处理文件同目录）

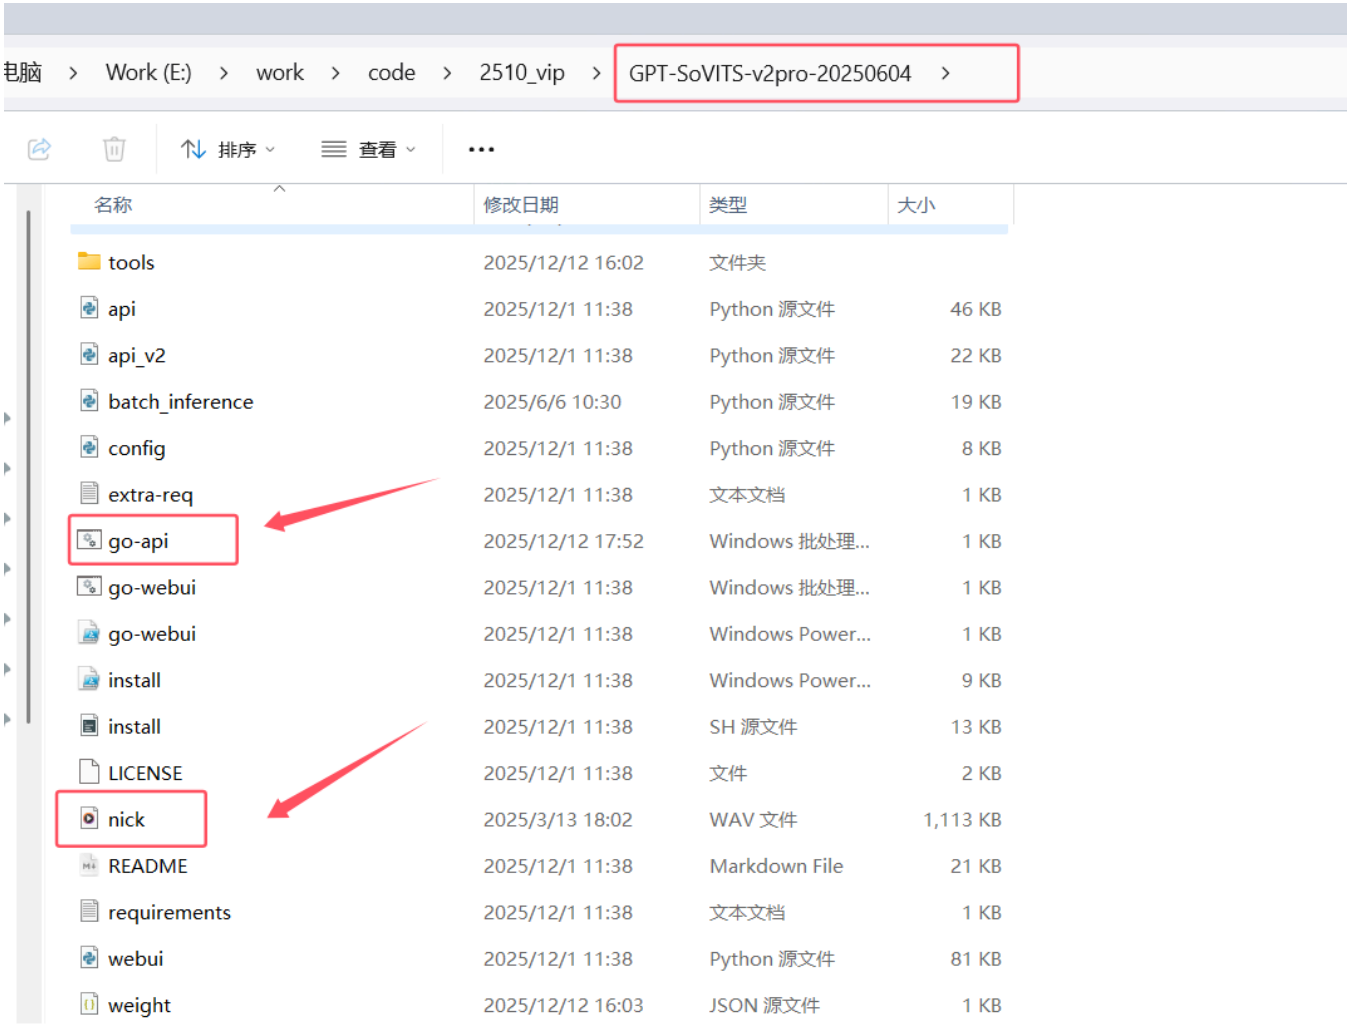
电脑 > Work (E:) > work > code > 2510_vip > GPT-SoVITS-v2pro-20250604 >
排序
查看
名称 修改日期 类型 大小
tools 2025/12/12 16:02 文件夹
api 2025/12/1 11:38 Python 源文件 46 KB
api_v2 2025/12/1 11:38 Python 源文件 22 KB
batch_inference 2025/6/6 10:30 Python 源文件 19 KB
config 2025/12/1 11:38 Python 源文件 8 KB
extra-req 2025/12/1 11:38 文本文档 1 KB
go-api 2025/12/12 17:52 Windows 批处理... 1 KB
go-webui 2025/12/1 11:38 Windows 批处理... 1 KB
go-webui 2025/12/1 11:38 Windows Power... 1 KB
install 2025/12/1 11:38 Windows Power... 9 KB
install 2025/12/1 11:38 SH 源文件 13 KB
LICENSE 2025/12/1 11:38 文件 2 KB
nick 2025/3/13 18:02 WAV 文件 1,113 KB
README 2025/12/1 11:38 Markdown File 21 KB
requirements 2025/12/1 11:38 文本文档 1 KB
webui 2025/12/1 11:38 Python 源文件 81 KB
weight 2025/12/12 16:03 JSON 源文件 1 KB

接口调用效果

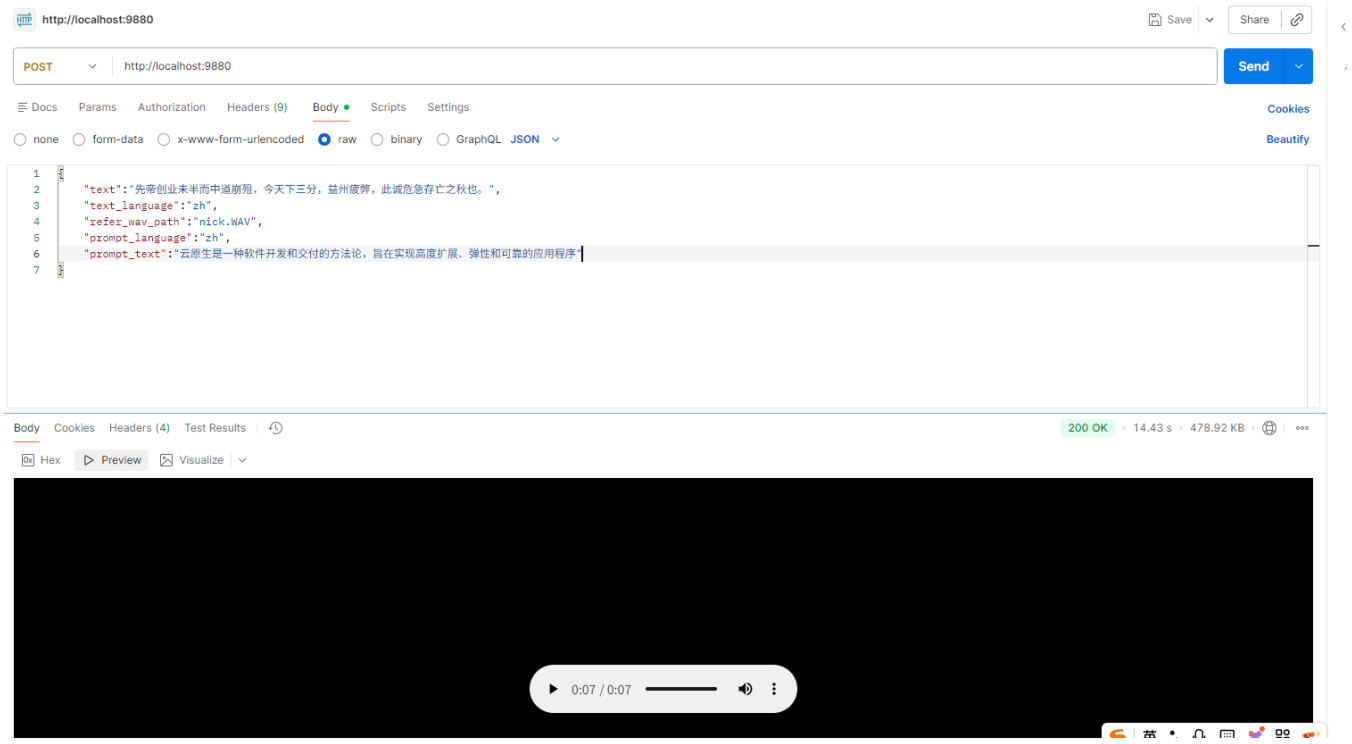
http://localhost:9880
Save
Share
POST
http://localhost:9880
Send
Docs
Params
Authorization
Headers (9)
Body
Scripts
Settings
Cookies
none
form-data
x-www-form-urlencoded
raw
binary
GraphQL
JSON
Beautify
"text":"先帝创业未半而中道崩殂，今天下三分，益州疲弊，此诚危急存亡之秋也。",
"text_language":"zh",
"refer_wav_path":"nick.WAV",
"prompt_language":"zh",
"prompt_text":"云原生是一种软件开发和交付的方法论，旨在实现高度扩展、弹性和可靠的应用程序"
Body
Cookies
Headers (4)
Test Results
200 OK
14.43 s
478.92 KB
Hex
Preview
Visualize
0:07 / 0:07

Linux Docker 运行

镜像下载（现有镜像）

```
# 仅包含gptSOVITS应用程序，不包含模型
docker pull quay.io/0voice/gpt-sovits-api:1.0.2

# 仅包含gptSovits相关模型
docker pull quay.io/0voice/gpt-sovits-api-model:1.0.0
```

构建镜像（Dockerfile）

1. 下载资源文件：https://pan.baidu.com/s/1lBduIZNNX3Qdl5uYC6CnBA?pwd=sq3u

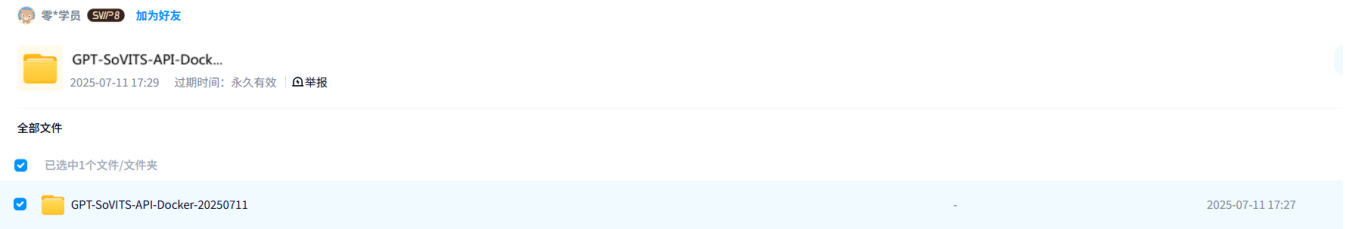

2. 构建gpt-sovits-api镜像，进入目录：GPT-SoVITS-API-Docker-20250711/api

名称	修改日期	类型	大小
GPT-SoVITS	2025/12/13 15:47	文件夹	
Dockerfile	2025/12/12 22:43	文件	2 KB
nick	2025/3/13 18:02	WAV 文件	1,113 KB
Python-3.10.13	2025/3/13 18:03	WinRAR 压缩文件	25,500 KB

```
docker build -t gpt-sovits-api:1.0.0 .
```

3. 构建带有模型的gpt-sovits-api-model镜像，进入目录：GPT-SoVITS-API-Docker-20250711/model

名称	修改日期	类型	大小
G2PWModel	2025/12/12 15:07	文件夹	
pretrained_models	2025/12/12 15:07	文件夹	
Dockerfile	2025/7/11 15:36	文件	1 KB

```
docker build -t gpt-sovits-api-model:1.0.0 .
```

启动服务

创建模型容器

1. 运行以下命令，通过容器创建存储卷，用于共享模型

```
docker run -d --name gpt-sovits-api-model gpt-sovits-api-model:1.0.0
```

启动服务（CPU推理）

```
docker run -d --name gpt-sovits1 --volumes-from gpt-sovits-api-model \
-p 9881:9880 --shm-size="16G" \
-v ai-transform-refer-vol:/app/GPT-SoVITS/runtime/refer \
gpt-sovits-api:1.0.0 python3 api.py -dl zh -d cpu -fp -p 9880
```

启动服务（GPU推理）

1. 需要在有Nvidia显卡的物理机上运行，以下为Nvidia显卡驱动信息

```
(GPTSoVits) nick@ubuntu:~/GPT-SoVITS4$ nvidia-smi
Sat May 18 13:48:25 2024
+-----------------------------------------------------------------------------------------+
| NVIDIA-SMI 535.161.08             Driver Version: 535.161.08   CUDA Version: 12.2     |
|-----------------------------------------+----------------------+----------------------+
| GPU  Name                 Persistence-M | Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp   Perf          Pwr:Usage/Cap |         Memory-Usage | GPU-Util  Compute M. |
|                                         |                      |               MIG M. |
|=========================================+======================+======================|
|   0  Tesla P40                      Off | 00000000:84:00.0 Off |                    0 |
| N/A   36C    P0              47W / 250W |      0MiB / 23040MiB |      1%      Default |
|                                         |                      |                  N/A |
+-----------------------------------------+----------------------+----------------------+

+-----------------------------------------------------------------------------------------+
| Processes:                                                                              |
|  GPU   GI   CI        PID   Type   Process name                            GPU Memory |
|        ID   ID                                                             Usage      |
|=========================================================================================|
|  No running processes found                                                             |
+-----------------------------------------------------------------------------------------+
```

2. docker运行，必须安装cuda插件
3. 启动服务

```
docker run -d --name gpt-sovits1 --volumes-from gpt-sovits-api-model \
--runtime=nvidia --gpus all -p 9881:9880 --shm-size="16G" \
-v ai-transform-refer-vol:/app/GPT-SoVITS/runtime/refer \
gpt-sovits-api:1.0.0
```

访问服务

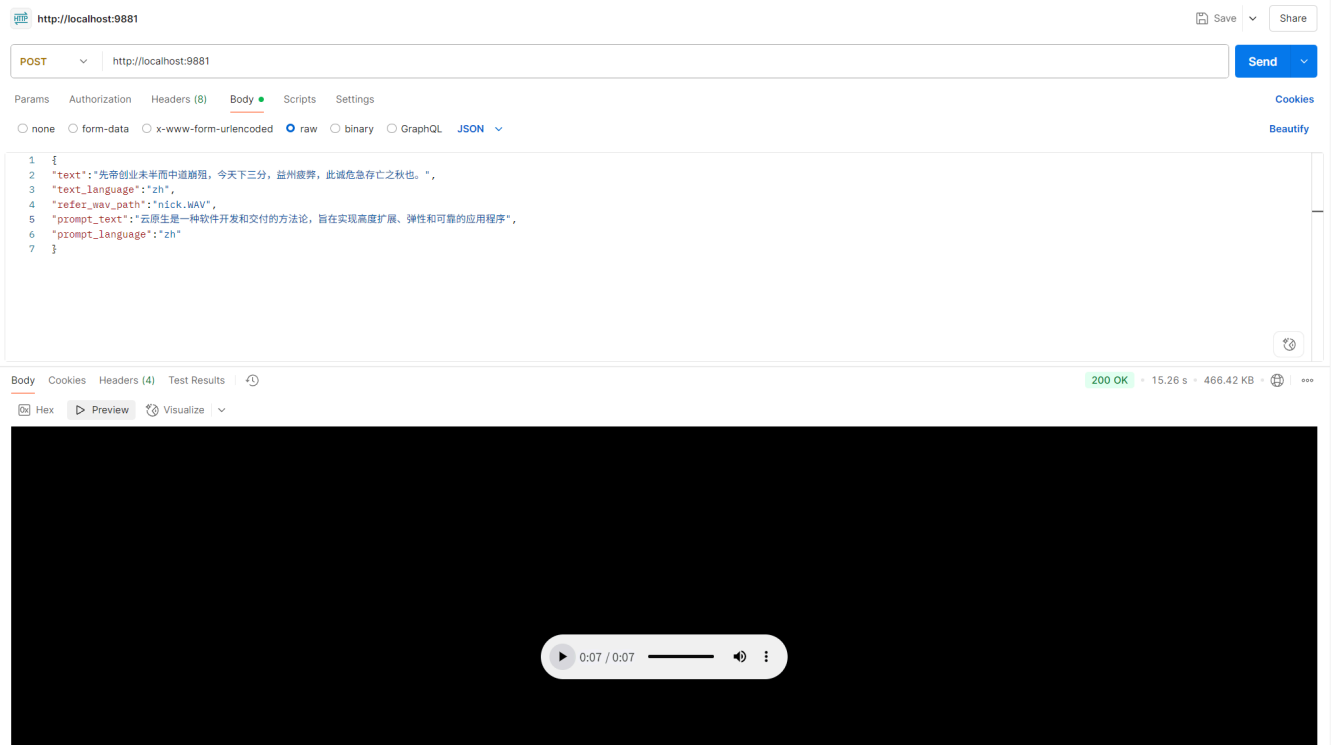
http://localhost:9881
Save
Share
POST
http://localhost:9881
Send
Params
Authorization
Headers (8)
Body
Scripts
Settings
Cookies
none
form-data
x-www-form-urlencoded
raw
binary
GraphQL
JSON
Beautify
{
"text":"先帝创业未半而中道崩殂，今天下三分，益州疲弊，此诚危急存亡之秋也。",
"text_language":"zh",
"refer_wav_path":"nick.WAV",
"prompt_text":"云原生是一种软件开发和交付的方法论，旨在实现高度扩展、弹性和可靠的应用程序",
"prompt_language":"zh"
}
Body
Cookies
Headers (4)
Test Results
200 OK
15.26 s
466.42 KB
Hex
Preview
Visualize
0:07 / 0:07

#